

Evoluzione del Vocabolario di un testo e Distribuzione delle Occorrenze

Studente: Giuseppe Di Placido

Marzo 2026

1 Introduzione

L'obiettivo di questo report è svolgere un'indagine computazionale su un corpus di testi della letteratura italiana e un'opera della letteratura cinese (*Il Romanzo dei Tre Regni*). Si analizzerà la relazione tra la lunghezza di un testo e la varietà del vocabolario impiegato, oltre alla distribuzione della frequenza di utilizzo delle parole, considerando testi di lingue diverse per valutare la conservazione di eventuali proprietà statistiche.

2 Risultati

2.1 a) Dinamica di accrescimento del vocabolario

L'analisi risponde alla domanda su come il numero di parole distinte (V) aumenti con la lunghezza totale del testo (N). Come evidenziato in **Figura 1 (sinistra)**, la crescita sembra seguire una legge di potenza. Il confronto inter-linguistico rivela una divergenza strutturale: mentre i testi italiani mostrano una crescita costante dovuta alla flessione morfologica, il testo cinese (linea nera, analizzato per singoli ideogrammi) presenta una saturazione molto più precoce. Come mostrato in **Figura 1 (destra)**, il punto relativo al testo cinese si posiziona significativamente più in basso rispetto alla tendenza italiana nonostante la vasta quantità di ideogrammi. Ciò indica che il repertorio di simboli grafici nel cinese è un set più limitato che tende a esaurirsi rapidamente, a differenza del vocabolario delle lingue europee.

Andamento parole distinte utilizzate con la lunghezza di un testo




Figura 1: A sinistra: crescita del vocabolario. La linea nera (Cinese) mostra la minor ricchezza di ideogrammi a disposizione. A destra: confronto della densità lessicale totale.

2.2 b) Distribuzione delle occorrenze

L'istogramma delle occorrenze analizzato in **Figura 2** mostra una distribuzione che segue una pendenza costante sia per i troncamenti dello stesso testo (**Figura 2, sinistra**) sia per il confronto tra opere diverse (**Figura 2, destra**). L'inclusione del testo cinese (**Figura 2, destra**, linea nera) mostra che nonostante la natura ideografica e la differente struttura della lingua, la distribuzione delle frequenze degli ideogrammi segue quasi perfettamente la pendenza dei testi italiani. Lo "zig-zag" nella coda della distribuzione è un fenomeno statistico dovuto alla discretezza dei dati per termini ad altissima frequenza, ma non inficia la validità della legge di potenza che governa il sistema linguistico umano indipendentemente dalla lingua considerata.

Comportamento dell'istogramma di occorrenza delle parole




Figura 2: A sinistra: stabilità della pendenza per troncamenti di un singolo testo.

A destra: l'allineamento della linea nera conferma l'universalità della legge anche per la lingua cinese.

3 Conclusioni

Le evidenze mostrano che la struttura del linguaggio è caratterizzata da leggi di potenza e, sebbene la ricchezza lessicale e la velocità di saturazione del vocabolario dipendano fortemente dal sistema di scrittura e dallo stile dell'autore, la distribuzione delle frequenze d'uso emerge come una proprietà universale della comunicazione umana.

4 Metodi

Il dataset è stato costruito tramite scraping (per testi italiani) e acquisizione manuale (per il testo cinese) da *Wikisource*. La pulizia dei dati in Python ha previsto due percorsi diversi per gestire le due lingue:

- **Testi Italiani:** È stata effettuata una pre-pulizia in fase di scraping, seguita da una post-elaborazione volta a separare i termini tramite spazi e punteggiatura. Per la gestione degli apostrofi (es. *"l'orario"*), si è optato per la separazione in parole distinte (*"l"*, *"orario"*).
- **Testo Cinese:** Data l'assenza di spaziatori grafici, si è proceduto all'estrazione dei singoli caratteri Hanzi utilizzando la proprietà Unicode `IsHan` tramite il modulo `regex`. Ogni ideogramma è stato trattato come unità lessicale minima (ogni ideogramma conta come una "parola").

I dati risultanti sono stati strutturati in un DataFrame *pandas* per il calcolo delle occorrenze e delle frequenze cumulative necessarie alla generazione dei plot.